

腎動脈影像切割與腹主動脈血管之 3D 建模

Renal Artery Image Segmentation and 3D Modeling of Abdominal Aortic Vessels

詹永寬^{指導教授}、黃泓睿、何佑昱、鄭宇原
國立中興大學資訊管理學系

摘要

本研究旨在利用電腦斷層掃描 CT 切片，開發一套自動影像處理和分析系統，以提升腹主動脈瘤治療的效能。在影像前處理階段，我們從 DICOM 格式中提取 CT 切片，並進行線性轉換生成 BMP 格式的影像。通過對比度調整和 Otsu's 二值化，實現了腹部血管結構的清晰呈現。接著引入了腎臟定位的影像識別步驟，採用 YOLOv4 和 YOLOv7 模型進行物件識別，成功識別並篩選出具有主動脈與腎動脈的切片影像。在影像分割方面，我們採用了 U-net 模型對血管輪廓進行分割，實現了對分割主動脈及分割主動脈與腎動脈連接處的精確分割。最終，透過前處理和建立體素點，本研究以三角網格建立了 STL 格式的血管輪廓 3D 模型，供醫療團隊於手術前進行評估。本研究的方法不僅有望提高腹主動脈瘤治療的精確性和效率，還為醫學影像處理領域的進一步研究提供了有益的參考。通過綜合應用各種影像處理技術和深度學習模型，為腹主動脈瘤的診斷和治療提供了一種全新的、更為精準的方法。

關鍵字：電腦斷層掃描、腹主動脈瘤、影像識別、影像切割、3D 建模

Abstract

This study aims to develop an automated image processing and analysis system using CT scans to enhance the treatment efficacy of abdominal aortic aneurysms (AAA). In the image preprocessing stage, we extracted CT slices from DICOM format and performed linear transformations to generate BMP format images. Through contrast adjustment and Otsu's binarization, we achieved a clear presentation of the abdominal vascular structures. Next, we introduced an image recognition step for kidney localization, employing YOLOv4 and YOLOv7 models for object detection, successfully identifying and selecting slices containing the aorta and renal arteries. For image segmentation, we used the U-net model to segment the vascular contours, accurately delineating the aorta and the connection between the aorta and renal arteries. Finally, through preprocessing and voxel point creation, we constructed an STL format 3D model of the vascular contours using a triangular mesh, providing the medical team with a tool for preoperative evaluation. The methods in this study not only aim to improve the accuracy and

efficiency of AAA treatment but also offer valuable references for further research in medical image processing. By integrating various image processing techniques and deep learning models, we provide a new, more precise approach for the diagnosis and treatment of abdominal aortic aneurysms. Keywords: Computed Tomography, Abdominal Aortic Aneurysm, Image Recognition, Image Segmentation, 3D Modeling

1.研究介紹

1.1 研究背景

腹主動脈瘤（Abdominal Aortic Aneurysm）是指腹部主動脈的血管壁變薄並膨脹擴張，如圖 1 所示，血管如氣球般膨脹的區域即為腹主動脈瘤。此病通常無明顯症狀，不易察覺。然而，若未經治療與追蹤，動脈瘤擴張到一定程度時有很高的破裂風險。一旦破裂會導致嚴重出血，危及生命。在美國，每年有至少 14000 人因腹主動脈瘤破裂[7]而死亡。因此及時發現並觀察治療腹主動脈瘤至關重要。

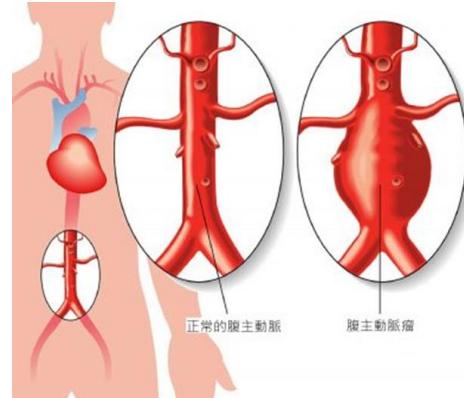


圖 1 腹主動瘤出現區域與形狀[6]

腹主動脈瘤的檢查主要依靠 CT 掃描和 MRI 掃描，以確認瘤體的大小和形狀。治療方法主要包括開放手術修補和血管支架植入。傳統的開放手術需要在腹部切口，切除異常擴張的主動脈並安裝人工血管。而血管支架植入是一種介入性手術，通過手臂或大腿動脈放置可擴張的金屬支架在主動脈瘤位置，以支撐血管壁，防止瘤體擴大或破裂，並減少手術創傷和恢復時間。

1.2 研究動機與目的

動脈瘤內腔修補手術是目前治療腹主動脈瘤的主要方法，但術後可能發生支血管壁與支架之間密合不足，血液仍能進入修補區域，導致治療無效。術前的 CT 掃描評估至關重要，可以了解瘤體

血管形狀、動脈夾角與血管流體走向。目前評估主要依靠醫療團隊人工判定，容易因視覺疲勞忽略細節，造成誤判。

本研究旨在解決上述問題，通過機器學習自動檢測與分析動脈瘤患部區域，減少視覺疲勞並提高評估效率。我們使用三維模型呈現主動脈瘤分割區域，幫助醫生更好地理解動脈瘤結構與流體走向，確保每個醫生使用相同資料進行評估，減少主觀因素，提高術前評估準確性。

本研究使用 CT 水平切面，獲取各器官的三維資訊與位置關係。以灰氏解剖學和動脈瘤內腔修補手術支架安裝位置為基準，使用 YOLOv4 與 YOLOv7 進行脊椎與腎臟特徵辨識，提取腹主動脈瘤區域資料，減少不必要的過程和計算時間。針對腹主動脈瘤區域切片，使用 U-net 語意分割模型將血管輪廓分割出來，根據切片間的關係建立三維體素(Voxel)，並以三角網格(Mesh)建立 STL 格式的 3D 模型，輔助醫療團隊進行判讀與治療。

2. 相關文獻

2.1 醫學知識、手術與解剖學

2.1.1 動脈瘤內腔修補手術

支架植入治療相比傳統手術更安全且有效。它利用局部麻醉，透過小切口將支架引入腹主動脈瘤血管中，以氣囊撐開支架取代受損血管，降低血液壓力，減少破裂風險。相比切開腹腔的手術，動脈瘤內腔修補手術 (EVAR) 更安全、簡潔且有效。如圖 2 所示，A 部分為傳統手術，需要從腹腔進入，切除動脈瘤擴張區域血管後縫上人工支架。B 部分為 EVAR，將可擴張支架導引至動脈瘤區域，充氣撐開支架取代擴張區域的血管功能。

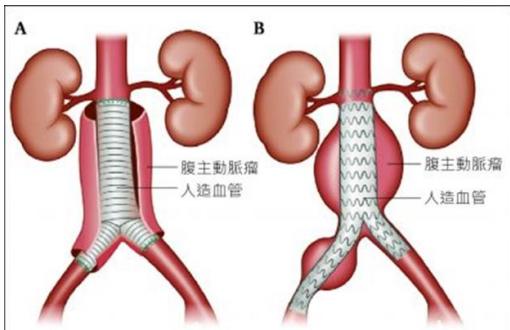


圖 2 傳統手術與動脈瘤內腔修補手術比較圖[20]

2.1.2 EVAR 手術支架安裝位置

在動脈瘤內腔修補手術中，支架會放置在腎動脈以下的主動脈區域，覆蓋動脈瘤但不阻隔血液循環至腎臟和其他器官，如圖 3 所示。腎動脈連接腎臟與主動脈支架，需以腎臟位置為基準，回溯腎動脈找到主動脈與腎動脈的連接處。因此，本研究將腎臟位置作為尋找腹主動脈瘤區域的重要參考。

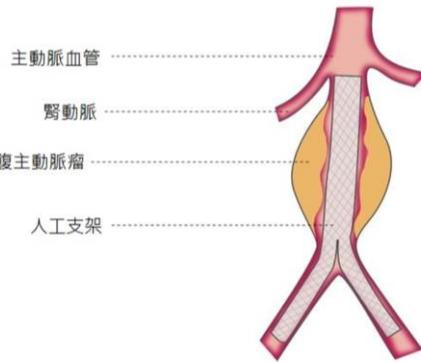


圖 3 人工支架安裝位置示意圖[2]

2.1.3 腎臟對應脊椎數出現區域

腎臟位於人體背部，位於脊椎的左右兩側。左右腎臟的位置因人而異，但根據灰氏解剖學，如圖 4，腎臟通常位於胸椎第 12 節至腰椎第 3 節之間。基於這一關係，本研究能從單張 CT 切片影像中，通過影像辨識判斷是否有主動脈瘤血管的出現。

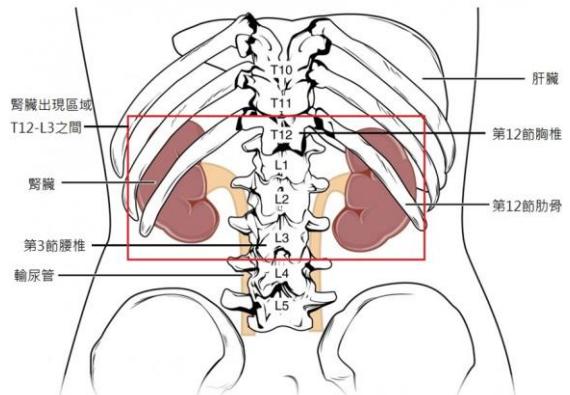


圖 4 腎臟與脊椎對應位置圖[3]

2.2 對比拉開

對比拉開 (Gamma Correction) [21][4] 是一種調整圖像亮度和對比度的影像處理方法，用於修正圖像的亮度曲線。在醫學影像中，對比拉開可改善影像的可視性並強化目標區域的細節。使用到了 Gamma 校正函數(2-1)對灰度值進行非線性轉換，其中為轉換後灰度值，為影像單一點的原灰度值，為影像所有灰度值最小值，為最大值，為 Gamma 校正值。

$$p' = \left(\frac{p - p_{min}}{p_{max} - p_{min}} \right)^r * 255 \quad (2-1)$$

2.3 卷積神經網路

卷積神經網路 (Convolutional Neural Network, CNN)[14] 在影像識別領域有顯著效果，廣泛應用於自然語言處理、聲紋分析和電腦視覺等領域。目前大多數影像辨識模型都是基於 CNN 結構開發的。CNN 由三個主要部分組成：卷積層 (Convolution Layer)、池化層 (Pooling Layer) 和全連接層 (Fully Connected Layer)。卷積層和池化層主要負責特徵提

取，全連接層則讀取和調整特徵，最後將這些特徵輸入分類器進行分類。2.3.1 到 2.3.3 分節將會針對這些層進行介紹。

2.3.1 卷積層

卷積層負責從圖像中提取特徵，通過不同濾波器（Filter）進行卷積運算來分析影像信息。卷積運算包括兩個步驟：首先，將大小為 4×4 的影像透過 2×2 的濾波器進行特徵擷取；其次，濾波器逐步遍歷整張影像，生成特徵圖（Feature Map）。

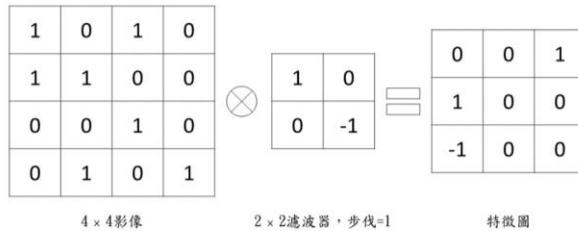


圖 5 卷積運算過程圖

2.3.2 池化層

池化層在卷積層後，作用是降低影像維度和權重，僅保留重要特徵，減少計算資源和時間。池化層使用平均池化（Mean Pooling）或最大池化（Max Pooling）兩種方式來遍歷特徵圖。平均池化取區域內像素值的平均值，最大池化取區域內的最大像素值。

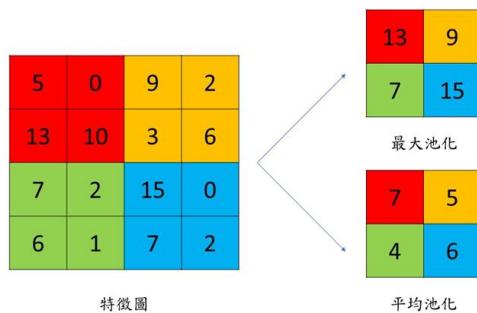


圖 6 池化層兩種運算過程圖

2.3.3 全連接層

經過卷積層和池化層提取特徵後，將特徵值輸入全連接層，所有特徵圖的權重連接並平坦化成一維陣列。根據輸出的概率進行分類，數值大小與預測結果正相關，輸出預測分類結果。

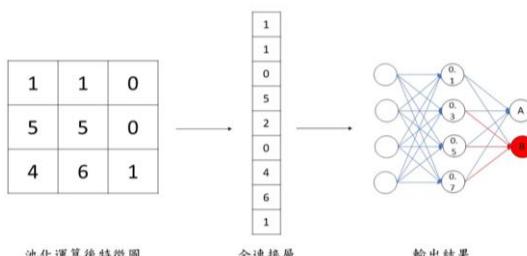


圖 7 全連接層與預測分類結果示意圖

2.4 物件偵測模型

2.4.1 YOLOv4

YOLOv4[1]是 YOLO 系列在 2020 年發表的第四版，延續了 YOLOv3 的架構，如圖 8 所示，分為 Input、Backbone、Neck 與 Head 四部分。Input 將原影像輸入以供特徵提取和偵測，Backbone 負責初步提取特徵，Neck 整合各層特徵圖，最後將 Neck 整合的特徵送入 Head 計算預測框。Head 分為一階段（Dense）和二階段（Sparse）兩種檢測器。Dense Prediction 在每個網格預測是否有預測框，Sparse Prediction 則在感興趣區域（ROI）做預測。YOLOv4 作為一階段檢測器，採用 Dense Prediction 方法。以下將介紹各部分及其方法。

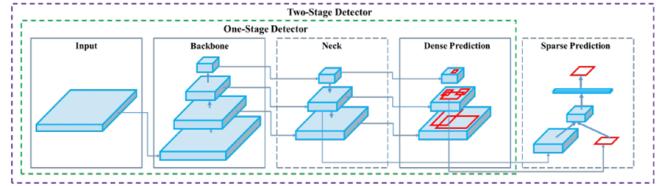


圖 8 YOLOv4 物件偵測架構圖[11]

Input 部分使用馬賽克數據增強（Mosaic Data Augmentation），參考 CutMix 方法，將四張圖片隨機縮放、裁切、排列後拼接成一張，增加了訓練圖片的資料量。

Backbone 部分改進了 YOLOv3 的 Darknet53，結合 CSPNet(Cross Stage Partial Network)，提出 CSPDarknet53。如圖 9 所示，CSPNet 將 base layer 分成兩份，一份原封不動，另一份進行卷積運算，最後合併傳遞至下一層。CSPDarknet53 通過 CSPNet 的連接方式，維持準確率的同時達到模型輕量化，減少 10%-20% 的計算量，並有效減少計算瓶頸。

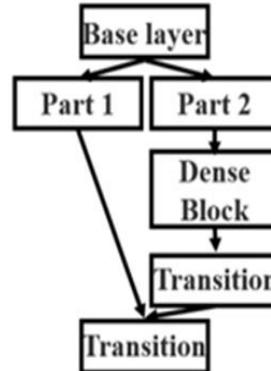


圖 9 CSPNet 架構圖[18]

於 Neck 部分捨棄常見的池化層，使用空間金字塔池化層 SPP(Spatial Pyramid Pooling)[5]，以 1×1 、 5×5 、 9×9 、 13×13 四種不同尺寸的卷積核（kernel）進行處理，再使用全連接層將不同大小的特徵圖連接並對輸出進一步分析，可以保障每個特徵圖包含不同尺度的資訊。SPP 架構可提升特徵偵測率，並且增加此網路的感受域（Receptive Field），用於適應不同尺寸、解析度的問題，結構可見圖 10 所示。

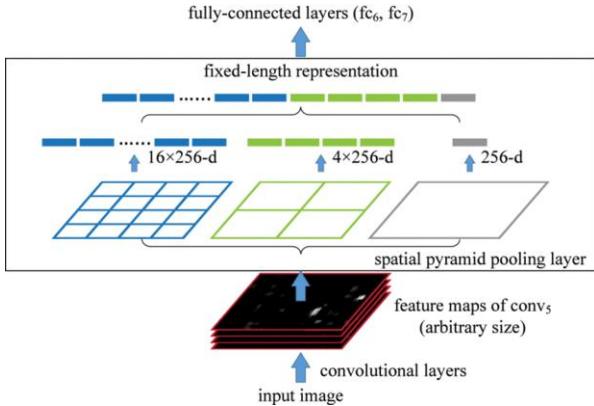


圖 10 空間金字塔池化層 SPP 網路結構[5]

路徑聚合網路 PANet(Path Aggregation Network)[8]通過增加一層全連接層，解決不同尺寸特徵融合問題。PANet由上採樣、下採樣與橫向連接三部分組成。上採樣區塊通過雙線性插值將低解析度特徵圖提升至高解析度，下採樣區塊通過最大池化將高解析度特徵圖縮小至低解析度。最後，橫向連接區塊將上、下採樣處理後的特徵圖串聯起來，生成一個帶有完整尺寸資訊的特徵圖。PANet融合各種尺寸特徵，以提高物件偵測準確率。詳細結構見圖 11。

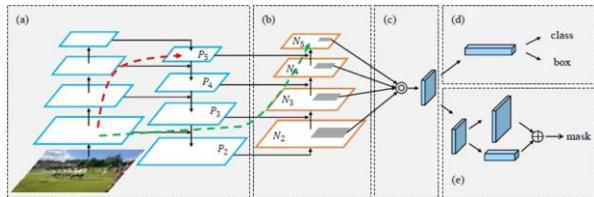


圖 11 PANet 完整結構[8]

最後 DensePrediction 部分主體與 YOLOv3 類似，主要將預測框篩選的非極大值抑制演算法更改成 DIoU 非極大值抑制演算法，目的在於在原本計算損失的基礎上加上一個懲罰(penalty)，最小化兩個預測框之間的中心點距離。

2.4.2 YOLOv7

YOLOv7[17]繼承自 YOLOv4，包含 Input、Backbone、Neck 和 Dense Prediction(Head)。影像輸入模型後，先經過 Backbone 提取特徵，再由 Neck 強化特徵，最後使用 Dense Prediction 預測並分類不同尺寸的特徵圖。輸入模型後，首先透過 Stem 和最大池化對特徵圖進行調整。Backbone 使用基於高效率層聚合網路 (Efficient Layer Aggregation Network, ELAN) 延伸出的擴充高效率層聚合網路 (Extended-Efficient Layer Aggregation Network, E-ELAN) [19]來提取特徵。ELAN 解決了深度模型在縮放後無法收斂的問題。隨著網路深度增加，繼續進行卷積運算不一定提高精度，反而增加運算成本和時間複雜度，可能導致性能下降。為改善此問題，YOLOv7 通過對基數 (Cardinality) 進行擴張 (Expand)、打亂 (Shuffle) 與合併 (Merge)，提升 ELAN 效能。這種方法在不破壞不同深度之間梯度穩定度的情況下，增加網路精度。ELAN 與 E-ELAN 詳細結構圖見圖 12。

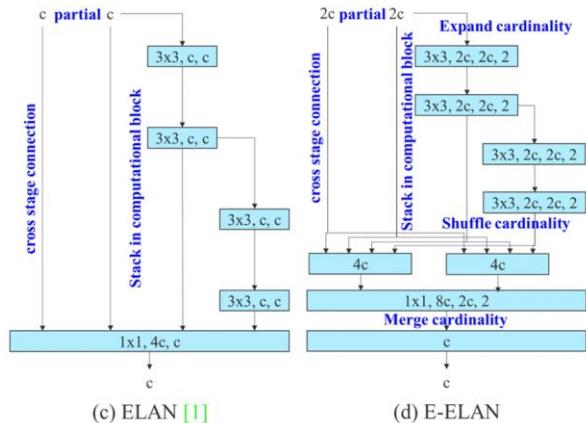


圖 12 ELAN 與 E-ELAN 結構比較[17]

Neck 區塊採用特徵金字塔網路 (Feature Pyramid Network, FPN) 將不同尺寸的特徵圖整合，增強不同範圍大小物件的檢測效果，並使用與 YOLOv4 相同的路徑聚合網路 (Path Aggregation Network, PANet)，結合低維度至高維度的特徵資訊，使特徵具有層次性。最終，Dense Prediction 將經 Neck 中 PANet 處理的特徵圖進行卷積運算，輸出三個不同尺寸的預測結果。

YOLOv7 相較於其他即時物件偵測方法，減少計算參數與計算量，降低時間複雜度，並提供更快的運算速度與更高的檢測精度。與其他即時運算方法的比較見圖 13。

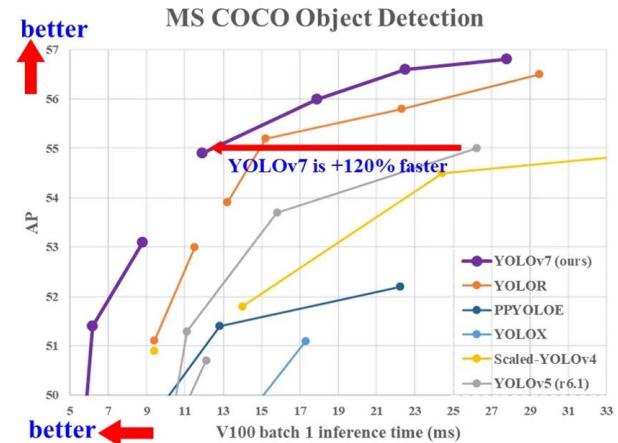


圖 13 YOLOv7 與其他即時運算方法的比較[17]

由於 YOLO 已是成熟的物件偵測技術，眾多文獻證實其效能。本研究使用 YOLOv4 與 YOLOv7 版本，利用其高精確度和即時運算效能，對影像進行脊椎與腎臟的辨識。這有助於判斷病患 CT 切片中哪些影像含有所需的腹主動脈瘤資訊，從而減少後續輪廓分割時對無用資訊切片的計算量。

2.5 物件分割模型

物件分割模型在影像視覺領域中，用於識別與準確標記圖像中的物件邊界，區分圖像中的不同物件，並精確地定位和標記每個物件的邊界。主要有語義分割(Semantic Segmentation)和實例分割(Instance Segmentation)兩種任務。語義分割將圖像

中的每個像素分配給其對應的物件或區域，而實例分割不僅識別物件的語義，還區分不同物件的實例，即在語義分割的基礎上進行分類。

U-net[12]基於全卷積神經網路(FCN)[9]，適用於語義分割。U-net的結構如圖 14 所示，由卷積與下採樣組成的編碼器，與反卷積與上採樣組成的解碼器對稱結合形成 U 型結構。在下採樣過程中，通過卷積計算得到特徵圖，使用池化層提取最大特徵值並讓影像大小減半，減少計算複雜度。解碼器每次上採樣時，對應的下採樣層數會通過跳躍連接輸入上採樣中，保留更多影像特徵。

由於 U-net 結構穩定，參數量少且不易過度擬合，適用於醫療影像這類病理結構位置固定、輪廓大小變化範圍有限的影像。因此，本研究採用 U-net 來分割動脈血管輪廓。

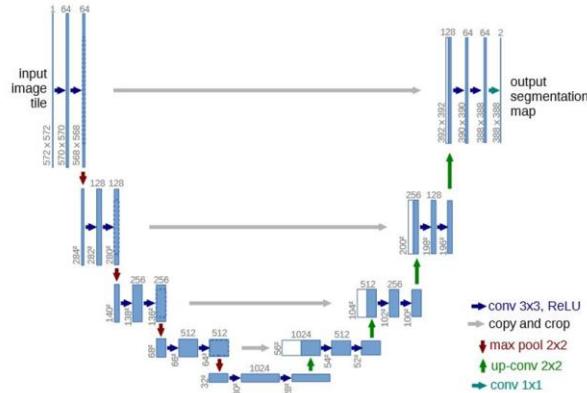


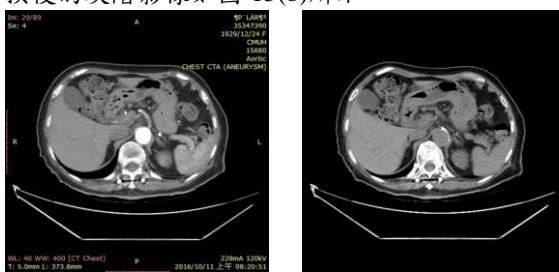
圖 14 U-net 架構[12]

3.研究方法

3.1 CT 影像前處理

3.1.1 DICOM 輸出 BMP

DICOM 是醫學影像的標準格式，用於保存 CT 等醫學影像，每個像素資料以-1000 至 1000 的亨氏單位儲存，並包含病患、就診、放射參數等醫療資訊。本研究將 DICOM 格式的 CT 水平面切片指定窗高(WL)=300、窗寬(WW)=600，進行線性轉換，輸出為灰度值 0-255 的 BMP 檔案，減少不需要的資訊供後續研究使用。原始 CT 切片如圖 15(a)所示，轉換後的灰階影像如圖 15(b)所示。

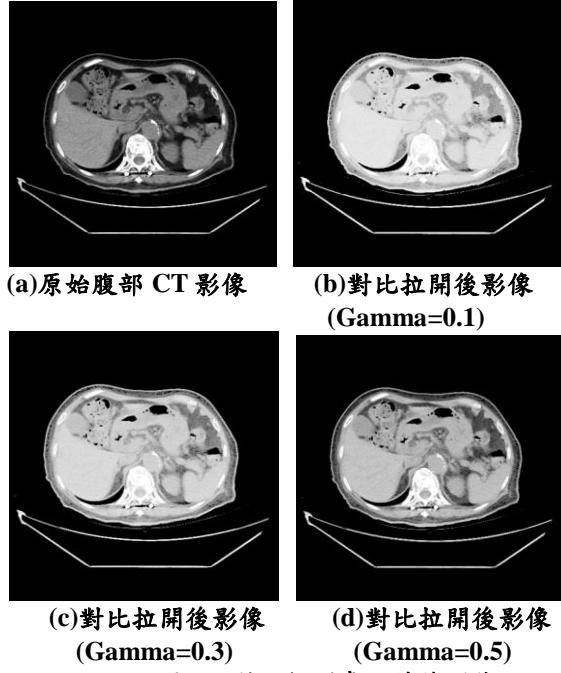


(a)原始 DICOM 格式
影像 (b)線性轉換後 BMP 格式影像

圖 15 DICOM 格式影像以及 BMP 格式影像

3.1.2 對比強化

取得 BMP 格式的 CT 切片影像後，為了只保留影像中軀幹的輪廓，去除其餘不必要的資訊，首先對影像使用對比拉開，將其設置 Gamma=0.1 的數值調整，降低影像的對比度，相較於其他參數值，Gamma=0.1 可使影像中的因亮度呈現的差異明顯降低。目的在於使切片中輪廓內的對比度降低，將軀幹輪廓的整體特徵凸顯出來。如圖 16 所示，對比強化處理的前後有明顯的差異，有助於後續進行提取主要軀幹的區域輪廓。

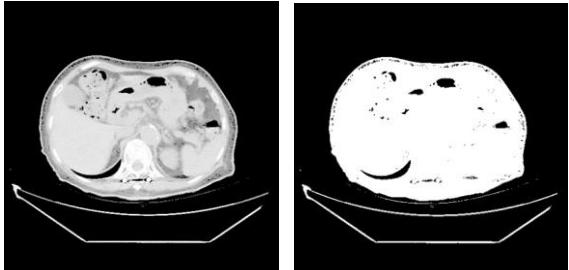


(c)對比拉開後影像
(Gamma=0.3) (d)對比拉開後影像
(Gamma=0.5)

圖 16 對比拉開處理前後影像

3.1.3 Otsu's 演算法(群間最大差異二質化)

將影像的對比度調低之後，使用 Otsu's 演算法[10]，自動取得影像的閾值，對影像各像素點進行二值化，將各像素的灰度值根據閾值二分成 0 以及 255 兩類。目的在於使用 Otsu's 演算法取得的閾值對影像進行二值化後，能更加有效地將影像的軀幹輪廓與背景以及其他無效資訊完整分離。如圖 17 所示，經過 Otsu's 演算法計算閾值，對每個像素點進行二值化後，主軀幹輪廓明顯的變成一塊從背景明顯獨立出來的區域。並且針對不同參數進行對比強化後的影像進行二值化，可以發現 Gamma=0.1 的數值相較其他更能完整分離出完整的軀幹輪廓。



(a) 對比拉開後影像
(b) Otsu's 二值化後
影像(Gamma=0.1)

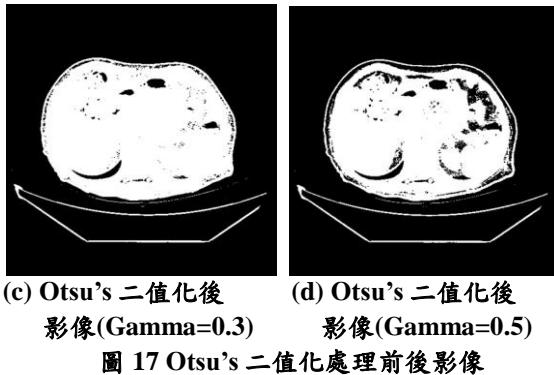


圖 17 Otsu's 二值化處理前後影像

3.1.4 連通分量標記

將影像經過二值化處理後，各個像素點都只剩下 0 與 255 兩種灰度值，此時使用連通分量標記[22]中的 8 連通將影像分為背景與數個由像素相連而聚集而成的輪廓。接著將除了背景以外最大的輪廓取出，此輪廓即是去除影像中無用資訊後，完整保留軀幹的輪廓。最後將此輪廓區域對應像素點儲存，並以此輪廓作為遮罩，將原影像與遮罩相同位置的輪廓像素點取出，即為完整軀幹影像，以供後續定位辨識及分割血管所用。如圖 18 所示，以 8 連通將二值化影像經過連通分量標記方式，取得背景以外最大區域作為遮罩，便可完整地將原圖上的軀幹輪廓分離出來。

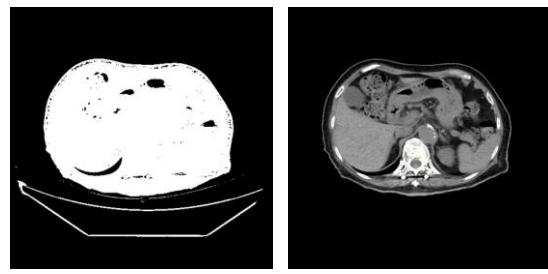


圖 18 8 連通標記處理後，從原圖分離出軀幹之影像

3.2 脊椎辨識定位

由於 CT 水平面的切片以 5 毫米為間距由上至下一次性拍攝整組影像，內含許多非腹主動脈瘤患部區域的切片。直接對整組影像進行影像分割不僅執行許多無意義的計算，還浪費大量計算資源與時間。腹主動脈瘤患部的位置特徵在於其位於左右兩腎臟之間，且發生於主動脈與腎動脈連接處以下。基於此，本研究首先以脊椎進行影像辨識，區分患部區域的切片影像。

影像經過前處理後，為了判斷該張切片是否位於腹主動脈瘤患部區域，將影像輸入物件辨識模型，偵測並且辨識該張影像中的脊椎形狀，辨識出單張切片影像中，脊椎形狀為脊椎的哪一類別，例如胸椎、腰椎，目的在於篩選出位於患部區域的切片影像。本研究根據灰氏解剖學，將胸椎與腰椎之

間定義為基準點，由此基準點往下 21 張切片影像為欲分割血管輪廓的腹主動脈瘤患部區域。為了篩選患部切片影像，本研究使用了 YOLOv4 網路訓練模型，並使用訓練出的模型對整組水平面切片影像進行辨識。

3.2.1 脊椎資料集標記

本研究使用 LabelImg[15]作為標記物件的工具，LabelImg 是一個專為標註圖像中物件的邊界框(Bounding Box)的軟體，提供直觀的圖形介面供使用者標記物件與增添標籤，並支援不同的圖檔與輸出不同模型所需的格式，例如 YOLO 訓練模型時所需的文字檔 txt 格式，實際操作介面可見圖 19。

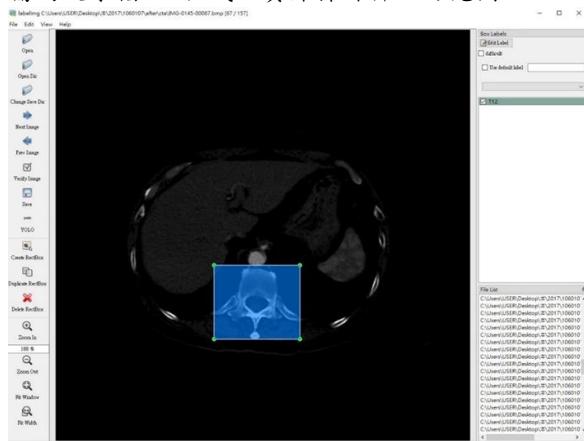


圖 19 LabelImg 操作介面

經過標記後儲存的物件資料格式為，其中 C 為該物件的類別，為該物件標記框中心對整張影像寬度的比值，為該物件標記框中心對整張影像高度的比值，為物件寬度對整張影像寬度的比值，為物件高度對整張影像高度的比值，其中為物件的左上角座標點，為物件的右下角座標點，具體可見圖 20。

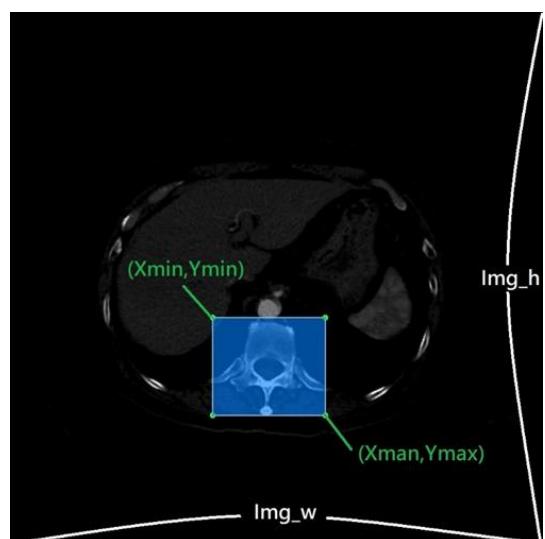


圖 20 YOLO 物件座標示意圖

3.2.2 辨識結果與胸椎與腰椎基準點

以 YOLOv4 訓練模型後，每張切片影像都會產生檢測框，並附帶其所屬類別和信心分數。根據這

些資訊，可以推斷該切片影像位於脊椎的哪一節位置。本研究以胸椎和腰椎之間作為參考點，判斷每張切片影像的分類和信心分數。當連續四張切片的信心分數都超過 0.9 時，將胸椎的最後一張和腰椎的第一張作為基準點，往下取得 21 張切片，即可得到腹主動脈瘤患部區域的切片資料。在訓練模型時，將信心分數設定為 0.01，目的是針對脊椎形狀進行更精確的分類，避免因 IOU 不足而導致模型未能正確分類脊椎。如圖 22 所示，信心分數超過 0.9 的胸椎與腰椎連續四張時，將胸椎與腰椎之間的兩張切片做為基準點，向下取得腹主動脈瘤患部區域切片。

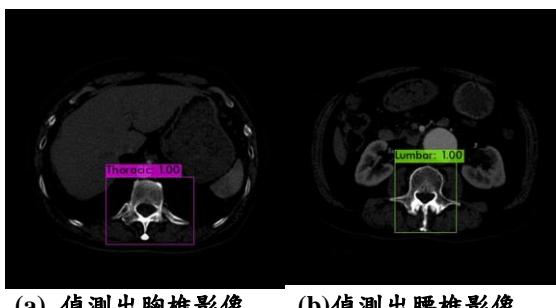


圖 21 經 YOLOv4 訓練後，偵測脊椎影像

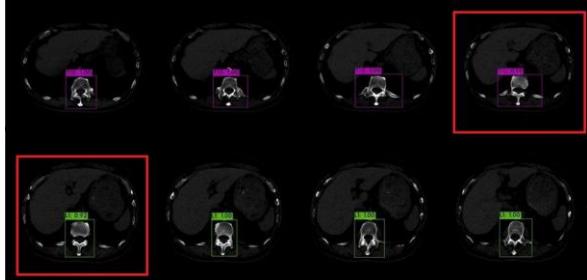


圖 22 胸椎與腰椎間基準點示意圖

3.3 腎臟辨識定位

為避免安裝支架後阻隔血液由主動脈傳輸至其他血管，所以須將支架安裝至腎動脈以下，腎動脈連接主動脈與腎臟之間，因此前一步驟篩選出的切片影像，需要再進一步針對腎臟進行辨識。

3.3.1 去除脊椎上下延伸之前處理

由於腎臟位於脊椎左右兩側，不與脊椎重疊，去除脊椎與上下延伸的影像資料能大大減少計算量，提升腎臟辨識效果。本研究利用前一步驟訓練所得的預測框(Bounding Box)來獲取脊椎的座標資料，如圖 23 所示。將偵測到的脊椎預測框上下延伸作為分割線，去除分割線內的影像，並將分割線左、右兩側的影像分別儲存為新影像，用於後續訓練模型及偵測左、右兩半部區域的腎臟。

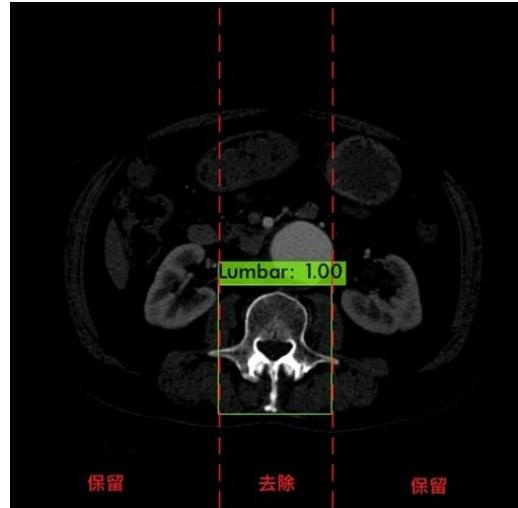


圖 23 去除脊椎上下延伸區域示意圖

3.3.2 腎臟物件偵測

為篩選出具有腎動脈的腹主動脈瘤影像，本研究使用了 YOLOv4 和 YOLOv7 模型進行訓練，並應用訓練出的模型對水平面切片影像進行腎臟辨識。本研究使用 LabelImg 作為物件標記工具，詳見章節 3.2.1。透過 YOLOv4 與 YOLOv7 模型，分別對去除脊椎上下延伸的左右半部分影像進行訓練。輸入對應模型時，每張切片會得到檢測框及其類別和信心分數(Confidence Score)，如圖 24 所示。

訓練模型時，信心分數設為 0.01，而非預設值 0.25，以避免因水平面切片下腎臟大小變化而導致模型辨識不到腎臟。經去除脊椎上下延伸後的左右半部切片影像輸入模型測試，保留信心分數超過 0.9 的切片，並依左右半部分開儲存。這些切片將用於後續步驟中建立主動脈與腎動脈血管輪廓資料集。

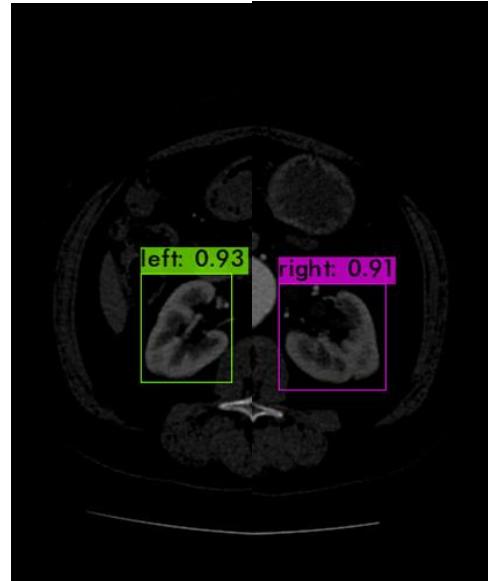


圖 24 YOLOv7 訓練後，偵測左、右半部之腎臟影像

3.4 血管輪廓分割

本研究的目的在於以血管輪廓建立三維的模型，在經過前處理與篩選具有腹主動脈瘤患部的切片後，需要將血管輪廓從切片影像中完整分離血管輪廓的每個像素點。U-net 作為廣泛應用於醫療影像領域的方法，其對於數量有限的資料集表現出色，並且能夠處理大小相較不固定變化的輪廓，因此本研究採用此方法對血管輪廓進行分割。

3.4.1 U-net 模型訓練與血管輪廓分割

首先，需要將前面幾個步驟篩選出來的切片資料，將目標區域輪廓的每個像素點進行標記，並且建立遮罩作為主動脈血管輪廓的基準輸入 U-net 進行訓練，如圖 25 所示，訓練出來的模型將原始影像分割出主動脈區域與背景區域兩個部分，分割出的主動脈血管輪廓將會用於建立可視化的三維模型。本研究使用 Labelme[16]作為標記物件的工具，是一個專為標註圖像中物件的輪廓遮罩的軟體，提供直觀的圖形介面供使用者手動繪製多邊形區域並將區域標記類別，以供建立遮罩使用，並支援不同的圖檔與輸出不同模型所需的格式，操作介面如圖 26 所示。

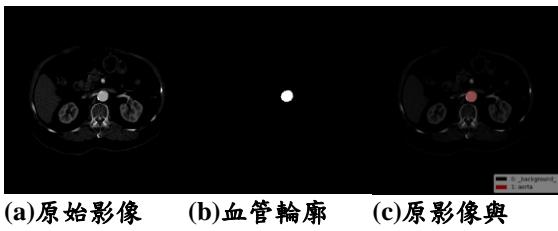


圖 25 主動脈血管輪廓標記遮罩示意圖



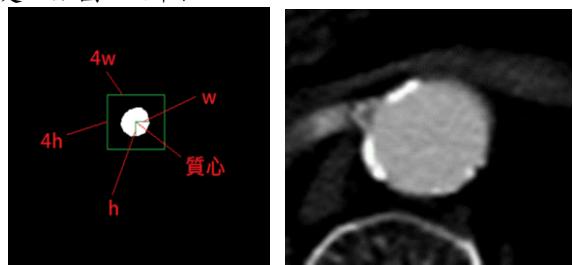
圖 26 labelme 標記操作介面

3.4.2 U-net 模型訓練腹主動脈與腎動脈血管輪廓分割

由於腹主動脈瘤安裝支架時需要確保支架位於腎動脈以下，因此主動脈和腎動脈的連接輪廓非常重要。因此，在第 3.3.2 章節中，本研究首先使用腎臟偵測定位方法篩選出具有腎臟的切片影像。接著，利用 U-net 模型訓練以分割出主動脈血管輪廓，然後使用這兩種資料集找出主動脈與腎動脈相連接的輪廓，並標記目標區域以建立遮罩資料

集。最後，再次使用 U-net 訓練模型以分割出主動脈與腎動脈相連接的輪廓。

由於主動脈與腎動脈相連接，所以欲分離相連接觸，從主動脈輪廓的邊緣周圍尋找即可，同時可以大幅度減少運算資料以及模型訓練時間。首先，將經過篩選具有腎臟的切片影像輸入分割主動脈輪廓的 U-net 模型當中，將模型輸出的主動脈輪廓的遮罩區域之質心點為中心，將遮罩的長、寬為基準向上、下、左、右延伸，以遮罩兩倍的長、寬建立矩形範圍，將此矩形框範圍從原圖中分離出來，如圖 27 所示。接著對分離出的影像以八連通偵測主動脈輪廓遮罩的邊緣，若有不為 0 的像素點，則將此影像儲存作為主動脈與腎動脈連接處的資料集，並且標記其完整輪廓的每個像素點，建立遮罩用並以 U-net 訓練並且分割主動脈與腎動脈連接處，如圖 28 所示。



(a)主動脈輪廓向外擴張之矩形範圍
(b)從原圖分離出影像

圖 27 以主動脈輪廓向外擴張矩形範圍示意圖



(a) 原始影像 (b) 血管輪廓 (c) 原影像與
標記遮罩 遮罩疊圖

圖 28 主動脈與腎動脈連接處血管輪廓標記遮罩示意圖

3.5 建立血管輪廓模型

取得完整血管輪廓之後，由於患部區域只有 21 張 CT 切片影像，以及血管並非如取出的血管輪廓一樣是實心的，因此需先對輪廓影像進行前處理取得血管邊緣，並以該影像的層數新增第三維的 z 軸值建立體素(Voxel)，最後以三角網格(Triangle Mesh)的方法建立 STL 格式[13]的三維模型。

3.5.1 邊緣前處理

首先將分割出來的主動脈血管輪廓，以形態學的侵蝕(Erosion)對血管輪廓影像進行處理，將原影像與其相減，這樣一來就只保留最外圍的像素，讓血管輪廓如同血管一般維持空心的狀態，如圖 29 所示。

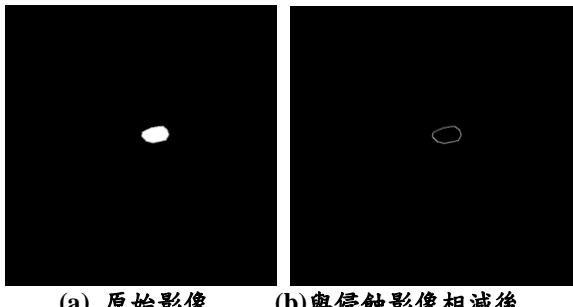


圖 29 血管輪廓邊緣處理示意圖

3.5.2 建立三維模型

將前一步驟取得的一連串邊緣輪廓影像中的每個像素座標(x,y)，以該像素點位於第幾層影像的二十倍為值，新增第三個座標值 z，以建立(x,y,z)體素點(voxel)，形成三維的空間關係。將層數拉大十倍是因為 CT 切片中的間隔為 0.5 公分，相當於 20px 的距離，能使建立出的三維模型空間關係近似於實際上的距離。接著將從上到下的每個體素點尋找下一層中與自身座標最近的兩個座標點，儲存成 $((x_1, y_1, z_1), (x_2, y_2, z_2), (x_3, y_3, z_3))$ 的結構，建立三角網格，並以 STL 格式儲存。如圖 30 所示，A、B 兩個三角面由上層的綠色、藍色兩體素點，向下尋找兩個距離最近的體素點，並儲存三點座標值形成三角網格。

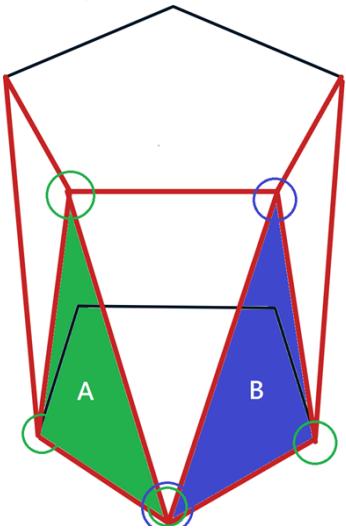


圖 30 以體素座標建立三角網格示意圖

4. 實驗結果與討論

本章節會說明本研究的實驗結果，並展示經過各實驗步驟後，產生的 STL 格式三維模型。本章節主要分為六個部分。分別會說明本實驗所使用的資料集、進行實驗時所使用的環境配置與評估指標、進行脊椎辨識定位所使用的參數與評估指標、進行腎臟辨識定位方法所使用的參數與評估指標、進行血管輪廓分割方法所使用的參數與分割評估指標，並於最後展示透過一連串步驟所產生的三維模型。

4.1 實驗使用資料集

本研究之資料集影像由中國醫藥大學附設醫院心臟外科提供，為病患就診時所拍攝之 CT 切片水平面影像，主要用於觀察腹主動脈瘤形狀與變化，本研究影像拍攝於 2016 年至 2022 年之間，一共 171 組病患的切片影像，影像尺寸固定為，並且切片之間的間隔為 5mm；在使用 YOLOv4 進行脊椎辨識定位步驟中，胸椎與腰椎兩種類別總共使用了 1377 張影像，以 1000 張影像進行訓練，377 張影像用於測試；在使用 YOLOv4 與 YOLOv7 進行腎臟辨識定位步驟中，使用脊椎左半部 403 張，脊椎右半部 405 張，共 808 影像，並以訓練、測試影像各 50% 的比率進行實驗；使用 U-net 進行血管輪廓分割步驟中，主動脈血管輪廓的影像一共 3328 張，並以訓練、測試影像各 50% 的比率進行實驗，各 1664 張影像；主動脈與腎動脈連接處的資料集，訓練使用 302 張，測試使用 201 張，一共 503 張影像。

4.2 脊椎辨識參數與各項指標

本小節中，會使用 Precision、Recall 與 F1 Score 三種指標，對以 YOLOv4 訓練出用以脊椎辨識定位的模型進行評估。其中訓練時所使用的參數如表 1 所示。

表 1 訓練脊椎辨識模型 YOLOv4 參數

名稱	參數描述
Size of Input images	512 X 512
Batch size	64
Subdivisions	16
Momentum	0.9
Learning Rate	0.00261
Decay	0.0005
IOU,Confidence	0.5, 0.01

訓練與測試共使用了 1377 張影像，以 1000 張影像進行訓練，377 張影像用於測試，用以辨識胸椎與腰椎兩類的特徵。其中 Precision 所代表的是辨識出脊椎類別時，實際上辨識正確的比例；Recall 所代表的是辨識出單一類別的脊椎時，實際辨識出正確種類比例；F1Score 衡量是否有出現資料不平衡的狀況；Average IOU 指的是偵測出的脊椎區域，佔實際區域的比例；mAP@0.5 指的是在 $IOU \geq 0.5$ 的情況下，將所有情況下的 Precision 平均後的指標，實驗數據如表 2 所示。

表 2 脊椎辨識模型測試結果

	Yolov4
Precision	0.93
Recall	0.95
F1-score	0.939
Average IOU	0.789
mAP@0.5	0.976

4.3 腎臟辨識參數與各項指標

本小節中，會使用 Precision、Recall 與 F1 Score 三種指標，對以 YOLOv4 與 YOLOv7 訓練出用以腎臟辨識的模型進行評估。訓練 YOLOv4 與 YOLOv7

模型時所使用的參數如表 3 所示。

表 3 訓練腎臟辨識模型 YOLOv4 與 YOLOv7 參數

名稱	參數描述
Size of Input images	512 X 512
Batch size	64
Subdivisions	16
Momentum	0.9
Learning Rate	0.00261
Decay	0.0005
IOU, Confidence	0.5, 0.01

訓練與測試共使用了 808 張影像，左腎區域 403 張，右腎區域 405 張，以各 50% 影像進行訓練與測試，用以一同與分開兩種方式訓練並辨識左、右腎臟的特徵。其中 Precision 所代表的是辨識出腎臟類別時，實際上辨識正確的比例；Recall 所代表的是辨識出單一類別的腎臟時，實際辨識出正確種類比例；F1 Score 則是衡量是否有出現資料不平衡的狀況；Average IOU 指的是偵測出的腎臟區域，佔實際區域的比例；mAP@0.5 指的是在 $\text{IOU} \geq 0.5$ 的情況下，將所有情況下 Precision 平均後的指標。左、右腎臟以 YOLOv4 與 YOLOv7 同時訓練並且辨識的實驗數據如表 4 所示，左、右腎臟以 YOLOv4 與 YOLOv7 分開訓練並且辨識的實驗數據如表 5 所示，可以看到分開訓練與辨識的結果比起同時來的好上許多。

表 4 YOLOv4、v7 同時訓練腎臟辨識模型測試結果

	Yolov4	Yolov7
Precision	0.84	0.78
Recall	0.86	0.87
F1-score	0.849	0.822
Average IOU	0.775	0.679
mAP@0.5	0.866	0.773

表 5 YOLOv4、v7 分開訓練腎臟辨識模型測試結果

	左腎		右腎	
	Yolov4	Yolov7	Yolov4	Yolov7
Precision	0.97	0.91	0.9	0.88
Recall	0.96	0.99	0.94	1.0
F1-score	0.969	0.948	0.919	0.936
AverageIOU	0.789	0.766	0.654	0.749
mAP@0.5	0.496	0.497	0.457	0.991

4.4 血管輪廓分割參數與各項指標

本小節中，會使用 Precision、Recall、F1 Score、Average IOU 與 Accuracy 五種指標，對以 U-net 訓練用以分割腹主動脈、主動脈與腎動脈連接處血管的模型進行評估。訓練 U-net 模型時所使用的參數如表 6 所示。

表 6 訓練血管分割模型 U-net 參數

名稱	參數描述
Size of Input images	512 X 512
Batch size	32
Random_Seed	42
Valid_Ratio	032
Learning Rate	0.002
Drop_Rate	0.5

進行主動脈分割時，訓練與測試共使用了 3328 張影像，以各 50% 影像進行訓練與測試，用以完整分割出腹主動脈血管輪廓。進行主動脈與腎動脈連接處分割時，訓練與測試共使用了 503 張影像，以 302 張影像進行訓練，並以 201 張測試，用以完整分割出主動脈與腎動脈連接處的血管輪廓。其中 Precision 所代表的是分割出血管輪廓時，分割出實際上正確像素的比例；Recall 所代表的是分割出血管輪廓時，實際分割出正確輪廓像素的比例；F1 Score 則是衡量是否有出現資料不平衡的狀況；Average IOU 指的是分割出的血管輪廓，佔實際輪廓的比例；Accuracy 是分割出的正確的目標血管輪廓像素，去除背景後佔整張影像中的比例。將腹主動脈輪廓、主動脈與腎動脈連接處血管，以 U-net 進行訓練與測試，並將本研究經前面幾個步驟處理後的影像，與未經處理的原圖進行比較，實驗數據如表 7 所示，可以發現在 Recall 與 Accuracy 有明顯的提升，並且能從 Average IOU 發現經過處理本研究處理後，分割出的血管輪廓影像與真實情況更加相近。

表 7 以 U-net 訓練血管分割模型測試結果

	經本研究步驟處理		原圖訓練	
	主動脈	主動脈+腎動脈	主動脈	主動脈+腎動脈
Precision	0.967	0.965	0.954	0.842
Recall	0.962	0.898	0.824	0.872
F1-score	0.964	0.93	0.884	0.856
Average IOU	0.932	0.872	0.799	0.759
Accuracy	0.953	0.838	0.81	0.858

4.5 STL 格式三維模型

本研究經過一連串步驟，透過辨識脊椎與腎臟兩種器官定位出目標腹主動脈瘤患部區域切片，並且分割出腹主動脈瘤患部血管輪廓，儲存成三維的體素點，用以建立 STL 格式的三維模型。圖 31 為建立三維模型前血管輪廓的影像，取得邊緣輪廓並擴增影像資料後，建立建立體素點並將每個體素點向上與向下最近的兩個的體素點建立三角網格，以 STL 格式儲存，最後得到的立體模型如圖 32(a)至圖 32(e)所示，礙於圖片無法很好展示模型的立體空間關係，故以五個角度的圖片進行呈現。建立出的三維模型兼具三維的空間資訊，並且如同真實血管一樣中空，能讓醫療團隊更好進行手術前的評估工作。

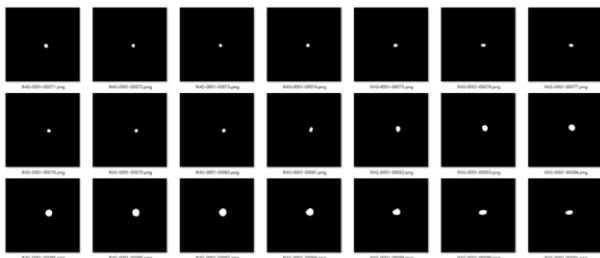
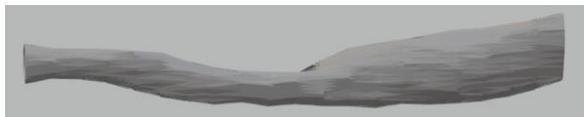


圖 31 建立三維模型前血管輪廓影像



(a)血管模型橫躺側視圖



(b)血管模型直立側視圖 (c)另一側血管模型直立側視圖



(d)血管模型俯視圖 (e)血管模型仰視圖

圖 32 三維血管模型各角度展示圖

5.結論與未來展望

本研究提出了一種針對腹主動脈瘤的自動化三維模型建立方法。從原始 CT 切片的 DICOM 格式影像轉換為 BMP 格式並進行前處理，提取軀幹輪廓。以脊椎和腎臟為目標器官，利用物件辨識模型 YOLOv4 和 YOLOv7 進行訓練，以辨識並篩選出患部區域的切片。針對患部區域的血管，使用 U-net 進行血管輪廓分割模型的訓練，實現完整的血管輪廓分割。最後，以型態學侵蝕處理，將原圖與其相減，得到僅有輪廓邊緣像素的影像，新增第三維的

數值建立體素，找到最近的兩端點形成三角網格，建立出呈現立體空間資訊的血管模型。

實驗結果顯示，血管輪廓分割的平均 IOU 達到 93.2%，精確度達到 95.3%。相較於單純對原圖進行分割的平均 IOU 為 79.9%，精確度為 81%，顯著提高。這有助於建立更貼近實際病患情況的立體模型。此外，本研究提出的方法所建立的三維模型未來可加入根據血管輪廓質心自動計算出血管中流體的走向，進而計算血管之間的角度變化。這提供給醫療團隊在手術前進行評估或手術中判斷病患的實際病理情況的可能性。

最後，由於病例資料數量有限，因此真正能分析的資訊也有所限制。期望在未來隨著資料量的增加，能夠訓練更優秀的模型供醫療團隊使用，使更多受腹主動脈瘤苦的病患能夠康復。此外，本研究主要針對手術前的影像進行處理並建立模型，未來期望擴展至術後影像的處理方法，實現對術前和術後的全方位自動分析。

參考文獻

- [1] Bochkovskiy, Alexey, Chien-Yao Wang, and Hong-Yuan Mark Liao. "Yolov4: Optimal speed and accuracy of object detection." arXiv preprint arXiv:2004.10934 (2020)..
- [2] Endovascular treatment of abdominal aortic aneurysms (EVAR) -CIRSE <https://www.cirse.org/patients/general-information/ir-procedures/endovascular-treatment-of-abdominal-aortic-aneurysms-evar/>
- [3] Gross Anatomy of the Kidney | Biology of Aging <https://courses.lumenlearning.com/atd-herkimer-biologyofaging/chapter/gross-anatomy-of-the-kidney/>
- [4] Guan, Xu, et al. "An image enhancement method based on gamma correction." 2009 Second international symposium on computational intelligence and design. Vol. 1. IEEE, 2009.
- [5] He, Kaiming, et al. "Spatial pyramid pooling in deep convolutional networks for visual recognition." IEEE transactions on pattern analysis and machine intelligence 37.9 (2015): 1904-1916.
- [6] <https://vascular.luxliving.hk/aaa/>
- [7] Kent, K. Craig, et al. "Analysis of risk factors for abdominal aortic aneurysm in a cohort of more than 3 million individuals." Journal of vascular surgery 52.3 (2010): 539-548.
- [8] Liu, Shu, et al. "Path aggregation network for instance segmentation." Proceedings of the IEEE conference on computer vision and pattern recognition. 2018.
- [9] Long, Jonathan, Evan Shelhamer, and Trevor Darrell. "Fully convolutional networks for semantic segmentation." Proceedings of the

- IEEE conference on computer vision and pattern recognition. 2015.
- [10] Otsu, Nobuyuki. "A threshold selection method from gray-level histograms." IEEE transactions on systems, man, and cybernetics 9.1 (1979): 62-66.
- [11] R. E. Turner, "Lecture 14 : Convolutional neural networks for computer vision," 2014.
- [12] Ronneberger, Olaf, Philipp Fischer, and Thomas Brox. "U-net: Convolutional networks for biomedical image segmentation." Medical Image Computing and Computer-Assisted Intervention–MICCAI 2015: 18th International Conference, Munich, Germany, October 5-9, 2015, Proceedings, Part III 18. Springer International Publishing, 2015.
- [13] STL(file format) – Wikipedia
[https://en.wikipedia.org/wiki/STL_\(file_format\)](https://en.wikipedia.org/wiki/STL_(file_format))
- [14] Teilo, K. "An Introduction to Convolutional Neural Networks." arXiv preprint arXiv:1511.08458 (2015).
- [15] Tzutalin. *LabelImg*. Git code (2015).
<https://github.com/tzutalin/labelImg>.
- [16] Wada, K. (November). Labelme: Image Polygonal Annotation with Python. Retrieved November 7, 2018
<https://github.com/wkentaro/labelme>
- [17] Wang, Chien-Yao, Alexey Bochkovskiy, and Hong-Yuan Mark Liao. "YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors." Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023.
- [18] Wang, Chien-Yao, et al. "CSPNet: A new backbone that can enhance learning capability of CNN." Proceedings of the IEEE/CVF conference on computer vision and pattern recognition workshops. 2020.
- [19] Wang, Chien-Yao, Hong-Yuan Mark Liao, and I-Hau Yeh. "Designing network design strategies through gradient path analysis." arXiv preprint arXiv:2211.04800 (2022).
- [20] Wanhainen, A., et al. "European Society for Vascular Surgery Guidelines on the management of Aorto-iliac Abdominal Aortic Aneurysms."
- [21] Xu, Chenyang, and Jerry L. Prince. "Snakes, shapes, and gradient vector flow." IEEE Transactions on image processing 7.3 (1998): 359-369.
- [22] Suzuki, Satoshi. "Topological structural analysis of digitized binary images by border following." Computer vision, graphics, and image processing 30.1 (1985): 32-46.